

基于气象特征的光伏功率预测研究

方向 A 刘诗妍 3120250901130

电气工程及其自动化 25-1 班

2026 年 10 月 8 日

目录

1	引言	3
1.1	研究背景	3
1.2	研究问题与分析	3
2	数据与预处理	3
2.1	数据来源与获取	3
2.2	数据的预处理	3
3	方法	4
3.1	特征选择	4
3.2	数据集划分	4
3.3	基线模型与主模型	4
3.4	LSTM 模型的对比	5
3.5	天气分场景	5
3.6	评价指标	5
4	结果与分析	5
4.1	各特征与功率的关系分析	6
4.2	基线模型与主模型对比	7
4.3	天气分场景建模预测（拓展要求 3）	8
4.4	LSTM 模型预测对比分析（拓展要求 4）	9
5	讨论与展望	9
5.1	结合双碳目标与电网调度讨论误差影响（拓展要求 6）	9
5.2	研究局限与改进	10
6	结论	10

1 引言

1.1 研究背景

“十五五”是实现碳达峰的关键期，在“碳达峰、碳中和”双碳战略目标背景下，截至 2025 年底，全国光伏发电量 1.17 万亿千瓦时 [1]，光伏发电作为清洁能源的主力军，正在实现大规模参与日常发电工作。然而，光伏发电具有较强的波动性和间歇性，极易受到气象条件的影响：如云层遮挡、温度变化等等。从实际发电工作情况来看，如果电网调度单位无法提前预知到光伏的发电功率，就难以合理规划发电计划，这不仅可能会造成需要时刻备用传统发电机组补充发电，增加了成本，而且还可能造成“弃光率”上升，这反而与双碳目标背道而驰。因此，光伏功率的准确预测是光伏发电更好应用在实际发电工作中，助力更好实现双碳目标，保障新能源合理利用的核心技术之一。

1.2 研究问题与分析

基于以上研究背景，本次研究的核心问题是：仅利用当日的辐照度、组件温度、环境温度等特征，能在多大程度上准确预测光伏电站的交流功率？研究这个核心问题时，可以让传统线性回归基线模型和随机森林等学习模型相比，比较了解不同模型预测准确度上的差距，了解 LSTM 等深度学习模型在小样本数据集下预测精度是否一定比传统树模型更高？（拓展要求）除此之外还可以分别比较在不同天气如晴天与阴天下预测的准确度如何？（拓展要求）最后分析一下在双碳目标下预测误差带来的实际影响（拓展要求）。

2 数据与预处理

2.1 数据来源与获取

本研究采用的 Kaggle 公开数据集（Solar Power Generation Data）[2]。该数据集包含印度两座光伏电站连续 34 天的运行记录，数据采集粒度为 15 分钟。本次研究主要选取 Plant 1 数据集，包含发电数据和气象传感数据。数据内容主要包括了：时间戳（DATE_TIME）、环境温度（AMBIENT_TEMPERATURE）、组件温度（MODULE_TEMPERATURE）、辐照度（IRRADIATION）以及交流发电功率（AC_POWER）。

2.2 数据的预处理

为了让实验的模型更好学习各特征与发电功率之间的关系，需要提前将数据集中的数据进行严格的预处理：1. 将文件中时间格式转换为标准格式，再以“时间”为纽带，采用内连接的方式将发电数据与气象传感数据拼接，构建包含完整气象特征和功率数据的数据表，确保每个时间点的特征和数据是一一对应的。2. 清洗数据，排除缺失值，避免缺失值对模型学习造成干扰，保留有效数据参与后续预测。将夜间辐照度为 0 时的无

效数据剔除，仅保留白天的有效数据参与后续预测，避免无效数据干扰模型训练。再排除缺失值，避免缺失值对模型学习造成干扰，保留有效数据参与后续预测。完成数据预处理环节后保留的数据集是可用于建模的高质量白天有效光伏发电的数据集，排除了夜间数据和空缺数据的干扰，特征和功率数据清晰，为下一步模型建立和学习训练奠定了有效的数据基础。

3 方法

本研究围绕“利用气象数据如辐照度、组件温度、环境温度等特征，预测光伏电站的交流功率”这一核心问题，设计相关的机器学习流程。总体思路为：先选取相关的气象特征作为模型输入，其次按时间顺序切分数据集以便模拟真实的预测场景，最后，通过基线模型与随机森林模型对比，以及分天气场景建模，验证模型的有效性。

3.1 特征选择

本次研究输入的特征包括了：辐照度(IRRADIATION)、环境温度(AMBIENT_TEMPERATURE)组件温度(MODULE_TEMPERATURE)。辐照度作为光伏发电的能量来源，是预测功率最核心的变量。环境温度反映了光伏电站所处的实时环境气象条件。引入组件温度是因为相较于环境温度组件温度更能体现光伏板自身状态，组件温度过高会导致光电转换效率下降，从而导致发电功率下降。输入这三个特征变量，能帮助模型更好捕捉光伏发电的特殊规律，发现“高温高光照下，实际功率反而降低”的特性。模型的预测目标为交流功率(AC_POWER)。

3.2 数据集划分

因为光伏发电的数据集是按照时间顺序排列，本次研究在划分训练集和测试集时，没有采取随机打乱的方式，而是按照时间顺序选择了前 80% 的数据为训练集，后 20% 的数据作为测试集。这样的测试方式符合真实场景应用即用历史规律来预测未来天气，这样也有效防止了数据泄露，保证了测试的严谨性与真实性。

3.3 基线模型与主模型

1. 基线模型：采用了传统的线性回归模型为基准。它能简单直观展示辐照度与功率的线性关系，为后续的主模型提供了“最低参考标准”，以便于更好观察主模型捕捉规律的能力。2. 主模型：此次研究采用的是随机森林，属于集成学习法，它通过有放回抽样构建了多棵决策树，并在每个节点随机选取特征进行分裂，最后取所有树的预测平均值。这种方式可以更加准确有效捕捉气象特征与功率之间的复杂关系。

3.4 LSTM 模型的对比

为了探索不同模型预测的结果的准确性，本次研究也尝试引入长短期记忆网络 (LSTM)。理论上其优势为拥有“记忆”能力，能够动态响应突变天气，提前感知变化，预判并输出更贴合动态曲线的预测值，从而解决云层遮挡带来的滞后失效问题。但本次实验的研究数据仅有 34 天记录，属于小样本数据，LSTM 庞大的参数量极易产生过拟合。引入的目的也是为了对比一下：在有限的數據下，传统树模型和 LSTM 模型的性能差异，以及对比双方的优劣势。

3.5 天气分场景

本次研究将额外把晴天阴天分开建模评估，以此来对比在不同天气下模型预测的准确度，以便更好了解模型的预测准确度。为了避免主观设定阈值的局限性，本研究采用了变异系数 ($CV = \text{标准差} / \text{均值}$) 来对天气进行客观划分。CV 值较小，曲线较平滑，则定义为“晴天”，CV 值较大，说明因为云层遮挡导致曲线较为波动，定义为“阴天”。随后，将数据集分为“晴天”“阴天”两个数据集，分别训练随机森林，对比 MAE 和 RMSE 的差异。

3.6 评价指标

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (1)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2)$$

本研究采用回归预测中最常用的两个指标：1. 平均绝对误差 (MAE)：反映了预测值和真实值绝对误差的平均水平，能直观反映模型整体预测的准确性。2. 均方根误差 (RMSE)：对误差先平方再开方。因为存在平方项，RMSE 对“断崖式下跌”或“极端天气”下的较大误差更加敏感。两者均是数值越小，则预测模型性能越好。

4 结果与分析

本研究围绕核心问题开展多组实验，以下通过各特征与功率关系分析、基线模型与主模型对比、天气分场景建模预测以及 LSTM 模型对比分析四个部分进行汇报。

4.1 各特征与功率的关系分析




图 1: 某典型日光伏电站交流功率输出曲线

图 1 展现了当天各时间段输出功率的变化，由图中可知，在当地清晨 5:30 以前和傍晚 19:00 以后由于日照不足，输出功率几乎为 0，随着太阳升起，日照强度增大，发电功率快速上升，并在当天中午 12:00-15:00 左右达到当天的功率峰值，约为 1200kW。误差分析：整幅图并不是平滑的抛物线，尤其是在上午 8:00-10:00 和中午 12:00-14:00 之间分别有一次断崖下跌，这样也揭露了光伏发电具有不稳定性，波动性，可能是由于云层遮挡导致的辐照度骤然下降导致的，这种波动也是需要精准预测功率的原因。




图 2: 辐照度与交流功率关系散点图

图 2 展示了辐照度与交流功率之间的关系，由图可知，辐照度与交流功率呈正相关关系，说明辐照度是影响光伏发电的核心气象因素。仔细观察图 2 可以发现随着辐照度不断升高，数据点构成的“带状”图像逐渐变宽，这也说明了，除了辐照度以外也存在其

他因素影响输出功率，例如发电组件随着工作时间增加温度升高后可能会影响光伏板光电转换效率，就算此时辐照度很高也会导致输出功率较小等等。




图 3: 白天环境温度直方图

图 3 展现了白天时段环境温度的频率分布，从图中可知白天的温度主要集中在 22°C-32°C 之间，整体呈现近似正态分布。可见环境温度对功率也有一定影响。

4.2 基线模型与主模型对比




图 4: 基线模型与随机森林模型预测对比图

本研究对比分析了基线模型与随机森林模型的预测能力。基线模型（线性回归）：MAE: 45.23, RMSE: 77.67 主模型（随机森林）：MAE: 36.23, RMSE: 72.95 图注：图中黑色实线为测试中的真实功率数据，蓝色虚线为基线模型，线性回归预测，橙色点划线代表随机森林，由图中三条线的变化曲线可知：两者的预测值趋势较符合真实值的变化

趋势，但是结合误差指标，线性回归的 MAE 为 45.23、RMSE 为 77.67，而随机森林的 MAE 降至 36.23、RMSE 为 72.95，实现了预测结果的优化，所以随机森林的曲线更加贴合真实值的波动情况，随机森林能更好地捕捉辐照度与温度之间的关系。观察到模型失效位置位于图线明显拐点处，不管是随机森林还是线性回归在云层遮挡导致功率骤然下跌时，预测曲线都存在滞后现象。这主要是因为当前模型只使用了“当前时刻”的气象数据，属于静态特征预测。如果当云层遮挡导致辐照度下降时，模型无法提前预知，这是未来需要引入“时间序列特征”和“天气分场景建模”的根本原因。

4.3 天气分场景建模预测（拓展要求 3）




图 5: 晴天与阴天场景下模型预测误差对比图

【Sunny 场景】MAE = 37.95, RMSE = 57.44 【Cloudy 场景】MAE = 29.06, RMSE = 48.21 在分场景建模中，可以观察到晴天场景的误差高于阴天，这并不是因为晴天的数据更难预测，而是因为晴天发电功率较大即基数较大，微小的相对误差折算成绝对误差就很大，并且晴天时组件温度较高，会导致光电转换效率会下降。阴天整体的功率基数小，绝对误差偏低。模型基于当前时刻气象数据的固定预测方式无法应对突变天气（如阴天云层遮挡等），这说明绝对误差指标存在盲区，未来可以试着引入相对误差等指标综合判断。

4.4 LSTM 模型预测对比分析（拓展要求 4）




图 6: LSTM 模型训练过程及预测误差表现

本研究尝试使用 LSTM 模型，理论上其优势为拥有“记忆”能力，能够动态响应突变天气，提前感知变化，预判并输出更贴合动态曲线的预测值，从而解决云层遮挡带来的滞后失效问题。但其表现为 $MAE=116.29$, $RMSE=144.77$ ，结果不如随机森林。深入剖析问题原因：本次数据仅包含 34 天记录（白天数据约为 3 万条），属于小样本数据集，但是 LSTM 模型参数量庞大，在小样本数据下容易发生过拟合，且训练耗时较长。这也证明了选择不同的学习模型得根据实际情况来定，在小样本数据条件下，传统随机树模型就足够，LSTM 模型需要海量数据才能发挥其长期记忆的优势。

5 讨论与展望

5.1 结合双碳目标与电网调度讨论误差影响（拓展要求 6）

在“碳达峰，碳中和”的宏观战略背景下，国家大力发展以光伏为代表的新能源，在电网工作场景中光伏发电也凸显其作用，但是通过这次较为详细的数据分析，可以深刻感受到光伏发电具有“看天吃饭”的不可控性和波动性。而电网调度部门往往就是需要维持“发电”与“用电”之间的平衡，因此光伏发电在助力双碳目标的同时，也给电网调度规划发电量时带来了巨大的压力。我们此次研究的“光伏发电预测”正是保障电网调度工作顺利进行，更好促进双碳目标的重要基础。预测误差对电网调度的具体影响：由实验数据可知，运用的不同模型（如随机森林模型，LSTM 模型，线性回归）和预测的不同天气场景（如晴天和阴天）的预测误差均存在一定明显的误差，这些误差运用到实际发电工作中会带来许多不便：例如若误差过大，导致相应的光伏发电过少时，为应对突发情况还得使用传统的发电方式，这不仅增加了发电的成本，还意味着一定程度上会给实现双碳目标制造阻碍；若因误差过大，导致相应的光伏发电过多时，也会造成能源

浪费；对于电网自身来说若因误差较大，为了应对光伏发电的波动性，往往需要备足够的储能工具，误差越大，储能成本也越大。由此可见，预测误差对双碳目标也有十分大的影响，若因误差过大，导致电网依旧要依赖传统发电方式来填补空缺发电量的话，会直接增加化石能源的消耗以及碳排放增加。因此提高光伏发电功率预测精确度，能够直接推动双碳目标进一步的实现。

5.2 研究局限与改进

本研究依旧存在局限性：1. 数据集样本较小，限制了 LSTM 深度学习模型的发挥。2. 分天气场景的划分标准仅有变异系数（CV）指标过于“单一化”，虽然这种方法能够客观量化辐照度的波动程度，但是现实生活中影响天气的类型的元素十分复杂。仅凭变异系数来划分晴天或阴天，可能会导致天气情况与真实气象存在偏差。3. 特征种类单一，缺乏气象多元的信息。仅使用了辐照度、环境温度、组件温度三个核心气象特征，但实际光伏发电还受风速、云层量等因素影响，当前特征无法完全反映真实天气情况。

针对以上不足，未来的深入研究可以从以下几个方面进行深化：1. 选择公开的大型光伏数据集，再分别使用随机森林和 LSTM 模型分析，以便更好观察随机森林和 LSTM 模型之间的区别和优劣势。2. 多维度与聚类算法优化天气分类：在后续研究中可以采用模糊 C 均值（FCM）聚类算法，引入偏度、峰度、标准差、均差等多维统计指标来对天气进行精准的划分 [3]。3. 多维度特征的采用：未来可以查找接入气象站的全面数据，引入风速、湿度云层量等特征进一步预测。4. 为电网调度工作提供概率预测：比如 13 号早上发电量在 900-1000kw 的概率为 80%，可以更加灵活的调整电网的发电工作。

6 结论

本研究基于 Kaggle 光伏数据集，围绕“利用气象特征预测光伏功率”这一核心问题，完成了从数据清洗预处理、基线与主模型对比、LSTM 模型探索与分天气场景建模的完整流程。得到以下结论：1. 机器学习明显优于传统基线：试验结果表明随机森林预测精度 MAE: 36.23, RMSE: 72.95, 传统基线模型的预测精度 MAE: 45.23, RMSE: 77.67, 随机森林的预测精度更高，这也证明了光伏发电与气象特征之间并非单纯的线性关系。2. 基于辐照度、环境温度、组件温度等特征，不同的模型预测情况不同：基线模型预测误差 MAE=45.23, RMSE=77.67；随机森林预测误差 MAE=36.23, RMSE=72.95；LSTM 模型预测误差 MAE=116.29, RMSE=144.77。3. 小样本数据下传统树模型更加有效：本研究发现 LSTM 模型在仅 34 天数据的小样本数据集中表现不佳，这说明深度学习模型的参数量与数据规模存在强相关性，在小样本数据集条件下，传统树模型更具优势。4. 阴天天气模型失效的可能性更大：实验中虽然晴天的绝对误差 MAE=37.95 比阴天的绝对误差 MAE=29.06 大，但是这只是因为晴天的发电基数大，微小的相对误差容易被放大成较大的绝对误差，实际上阴天云层遮挡会导致辐照度波动更加剧烈，结合 RMSE

指标来看,晴天 RMSE=57.44,阴天 RMSE=48.21,虽然阴天的误差小,但由于其辐照度波动较大,模型又存在预测滞后性,因此,阴天的预测失效风险较高。

参考文献

- [1] 国家能源局.2025 年可再生能源并网运行情况 [EB/OL].(2026-02-12)[2026-10-02].
<https://www.nea.gov.cn/20260212/742b8c6a078347b0b39de676c05c5d58/c.html>
- [2] Anikannal.Solar Power Generation Data[DB/OL].Kaggle,(2020-05-15)[2026-10-02].
<https://www.kaggle.com/datasets/anikannal/solar-power-generation-data>.
- [3] 吕伟杰,方一帆,程泽.基于模糊 C 均值聚类和样本加权卷积神经网络的日前光伏出力预测研究 [J].电网技术,2022,46(1): 231-238.