



RESEARCH DEFENSE

基于气象特征的光伏功率预测研究

西华大学电气Club学术组招新答辩

汇报人:刘诗妍

日期: 2026. 10. 14

目录

CONTENTS

01 研究背景与问题

02 实验数据

03 研究方法

04 研究结果

05 研究不足与个人收获





PART 01

研究背景与问题

双碳目标下的光伏发电

双碳目标下光伏大规模并网，但光伏发电具有“看天吃饭”的特性，容易受到天气特征的干扰，波动性大。预测不准容易导致碳排放增加，或弃光率上升，反而与双碳目标背道而驰。



核心问题：仅利用当日的辐照度、组件温度、环境温度等特征，能在多大程度上准确预测光伏电站的交流功率？

拓展要求：

- ① 基线模型vs主模型
- ② 晴天vs阴天
- ③ LSTM模型vs随机森林
- ④ 双碳目标下误差带来的实际影响

01

研究背景与问题

基线模型

传统线性回归模型

为后续的主模型提供了“最低参考标准”

简单直观展示辐照度与功率的线性关系

VS

主模型（随机森林模型）

随机森林模型


有放回抽样构建了多棵决策树，并在每个节点随机选取特征进行分裂，最后取所有树的预测平均值

更加准确有效捕捉气象特征与功率之间的复杂关系



PART 02

实验数据



The screenshot shows the Kaggle dataset page for 'Solar Power Generation Data'. The page header includes a search bar, a user profile for 'ANI KANNAL' (updated 6 years ago), and statistics: 1068 views, 411 code files, 25 discussions, and 0 suggestions. The dataset title is 'Solar Power Generation Data' with a subtitle 'Solar power generation and sensor data for two power plants.' and a thumbnail image of solar panels. Below the title, there are tabs for 'Data Card', 'Code (411)', 'Discussion (25)', and 'Suggestions (0)'. The 'About Dataset' section describes the data source and structure. The 'Usability' is 10.00, 'License' is 'Data files © Original Authors', and 'Expected update frequency' is 'Never'. The 'Tags' section includes 'Renewable Energy'. A footer note states 'Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic.'

Search

ANI KANNAL · UPDATED 6 YEARS AGO

1068

Code

Download

Solar Power Generation Data

Solar power generation and sensor data for two power plants.

Data Card Code (411) Discussion (25) Suggestions (0)

About Dataset

This data has been gathered at two solar power plants in India over a 34 day period. It has two pairs of files - each pair has one power generation dataset and one sensor readings dataset. The power generation datasets are gathered at the inverter level - each inverter has multiple lines of solar panels attached to it. The sensor data is gathered at a plant level - single array of sensors optimally placed at the plant.

There are a few areas of concern at the solar power plant -

1. Can we predict the power generation for next couple of days? - this allows for better grid management
2. Can we identify the need for panel cleaning/maintenance?

Usability 10.00

License Data files © Original Authors

Expected update frequency Never

Tags Renewable Energy

Kaggle uses cookies from Google to deliver and enhance the quality of its services and to analyze traffic. Learn more OK, Got it.



本研究采用的Kaggle公开数据集（Solar Power Generation Data）。该数据集包含印度两座光伏电站连续34天的运行记录，数据采集粒度为15分钟。



本次研究主要选取Plant 1数据集，包含发电数据和气象传感数据。数据内容主要包括了：时间戳（DATE_TIME）、环境温度（AMBIENT_TEMPERATURE）、组件温度（MODULE_TEMPERATURE）、辐照度（IRRADIATION）以及交流发电功率（AC_POWER）。



将文件中时间格式转换为标准格式，以“时间”为纽带，采用内连接的方式将发电数据与气象传感数据拼接，构建包含完整气象特征和功率数据的数据表。



清洗数据，排除缺失值，可以避免缺失值对模型学习造成干扰，剔除夜间无效数据，保留有效数据参与后续预测。





PART 03

研究方法



特征选取



数据集划分



基线模型与随机
森林模型



天气分场景预测



LSTM模型预测

特征选取

本次研究输入的特征包括了：辐照度（IRRADIATION）、环境温度（AMBIENT_TEMPERATURE）、组件温度（MODULE_TEMPERATURE）。辐照度作为光伏发电的能量来源，是预测功率最核心的变量。环境温度反映了光伏电站所处的实时环境气象条件。引入组件温度是因为相较于环境温度组件温度更能体现光伏板自身状态，组件温度过高会导致光电转换效率下降，从而导致发电功率下降。

按照时间顺序选择了前80%的数据为训练集，后20%的数据作为测试集。这样的测试方式符合真实场景应用即用历史规律来预测未来天气，这样也有效防止了数据泄露，保证了测试的严谨性与真实性。

数据集划分

线性回归模型

采用了传统的线性回归模型为基准。它能简单直观展示辐照度与功率的线性关系，为后续的主模型提供了“最低参考标准”，以便于更好观察主模型捕捉规律的能力。

VS

随机森林模型

随机森林模型，它通过有放回抽样构建了多棵决策树，并在每个节点随机选取特征进行分裂，最后取所有树的预测平均值。这种方式可以更加准确有效捕捉气象特征与功率之间的复杂关系。

03 天气分场景预测

采用了变异系数（ $CV = \text{标准差} / \text{均值}$ ）来对天气进行客观划分

晴天预测

CV值较小，曲线较平滑，则定义为“晴天”

VS

阴天预测

CV值较大，说明因为云层遮挡导致曲线较为波动，定义为“阴天”

LSTM模型预测

为了探索不同模型预测的结果的准确性，本次研究也尝试引入长短期记忆网络（LSTM）。理论上其优势为拥有“记忆”能力，能够动态响应突变天气，提前感知变化，预判并输出更贴合动态曲线的预测值，从而解决云层遮挡带来的滞后失效问题。引入的目的也是为了对比一下：在有限的数下，传统树模型和LSTM模型的性能差异，以及对比双方的优劣势。





PART 04


研究成果

04

各特征与功率的关系

结果分析

在当地清晨5:30以前和傍晚19:00以后由于日照不足,输出功率几乎为0,随着太阳升起,日照强度增大,发电功率快速上升,并在当天中午12:00-15:00左右达到当天的功率峰值,约为1200kW。




误差分析:

整幅图并不是平滑的抛物线,尤其是在上午8:00-10:00和中午12:00-14:00之间分别有一次断崖下跌,这样也揭露了光伏发电具有不稳定性,波动性,可能是由于云层遮挡导致的辐照度骤然下降导致的,这种波动也是需要精准预测功率的原因。


04

各特征与功率的关系



分析图象


图中展示了辐照度与交流功率之间的关系，由图可知，辐照度与交流功率呈正相关关系，说明辐照度是影响光伏发电的核心气象因素（仔细观察图可以发现随着辐照度不断升高，数据点构成的“带状”图像逐渐变宽，这也说明了，除了辐照度以外也存在其他因素影响输出功率）



分析图象

展现了白天时段环境温度的频率分布，从图中可知白天的温度主要集中在 22°C - 32°C 之间，整体呈现近似正态分布。

04 基线模型与主模型对比



线性回归模型

MAE: 45.23, RMSE: 77.67


VS

随机森林模型

MAE: 36.23, RMSE: 72.95

误差分析：观察到模型失效位置位于图线明显拐点处，不管是随机森林还是线性回归在云层遮挡导致功率骤然下跌时，预测曲线都存在滞后现象。这主要是因为当前模型只使用了“当前时刻”的气象数据，属于静态特征预测。如果当云层遮挡导致辐照度下降时，模型无法提前预知

04 天气分场景预测（拓展要求3）



晴天

VS

阴天

MAE = 37.95, RMSE = 57.44


MAE = 29.06, RMSE = 48.21

误差分析：在分场景建模中，可以观察到晴天场景的误差高于阴天，这并不是因为晴天的数据更难预测，而是因为晴天发电功率较大即基数较大，微小的相对误差折算成绝对误差就很大，并且晴天时组件温度较高，会导致光电转换效率会下降。阴天整体的功率基数小，绝对误差偏低。模型基于当前时刻气象数据的固定预测方式无法应对突变天气（如阴天云层遮挡等），这说明绝对误差指标存在盲区，未来可以试着引入相对误差等指标综合判断。

分析结果

其表现为MAE=116.29，
RMSE=144.77，结果不如随机森林。

深入剖析问题原因：本次数据仅包含34天记录（白天数据约为3万条），属于小样本数据集，但是LSTM模型参数量庞大，在小样本数据下容易发生过拟合，且训练耗时较长。这也证明了选择不同的学习模型得根据实际情况来定，在小样本数据条件下，传统随机树模型就足够，LSTM模型需要海量数据才能发挥其长期记忆的优势。。



```
"D:\Electrical Engineering\venv\Scripts\python.exe" "D:\Electrical Engineering\Day5_text.py"
D:\Electrical Engineering\Day5_text.py:10: UserWarning: Parsing dates in %d-%m-%Y %H:%M format when dayfirst=False (the default) was specified. Pass 'dayfirst=True' or specify a format to silence t
df_gen['DATE_TIME'] = pd.to_datetime(df_gen['DATE_TIME'])
数据准备完毕！训练集大小: torch.Size([30692, 10, 3])
开始训练 LSTM 模型...
Epoch 5/100, Loss: 0.2801
Epoch 10/100, Loss: 0.2305
Epoch 15/100, Loss: 0.1818
Epoch 20/100, Loss: 0.1322
Epoch 25/100, Loss: 0.0819
Epoch 30/100, Loss: 0.0391
Epoch 35/100, Loss: 0.0299
Epoch 40/100, Loss: 0.0374
Epoch 45/100, Loss: 0.0258
Epoch 50/100, Loss: 0.0236
Epoch 55/100, Loss: 0.0232
Epoch 60/100, Loss: 0.0202
Epoch 65/100, Loss: 0.0176
Epoch 70/100, Loss: 0.0165
Epoch 75/100, Loss: 0.0148
Epoch 80/100, Loss: 0.0133
Epoch 85/100, Loss: 0.0123
Epoch 90/100, Loss: 0.0113
Epoch 95/100, Loss: 0.0106
Epoch 100/100, Loss: 0.0100
训练完成，正在计算误差指标...
【LSTM 模型】MAE = 116.29, RMSE = 144.77
进程已结束，退出代码为 0
```



PART 05

研究不足与
个人收获



特征种类单一，缺乏气象多元的信息。

仅使用了辐照度、环境温度、组件温度三个核心气象特征，但实际光伏发电还受风速、云层量等因素影响，当前特征无法完全反映真实天气情况。



数据集样本较小

限制了LSTM深度学习模型的发挥



CV指标过于“单一化”

分天气场景的划分标准仅有变异系数（CV）指标过于“单一化”，虽然这种方法能够客观量化辐照度的波动程度，但是现实生活中影响天气的类型的元素十分复杂。仅凭变异系数来划分晴天或阴天，可能会导致天气情况与真实气象存在偏差



特征种类单一，缺乏气象多元的信息。

多维度特征的采用：未来可以查找接入气象站的全面数据，引入风速、湿度云层量等特征进一步预测。



数据集样本较小

选择公开的大型光伏数据集，再分别使用随机森林和LSTM模型分析，以便更好观察随机森林和LSTM模型之间的区别和优劣势。



CV指标过于“单一化”

多维度与聚类算法优化天气分类：在后续研究中可以采用模糊C均值（FCM）聚类算法，引入偏度、峰度、标准差、均差等多维统计指标来对天气进行精准的划分

个人收获（拓展要求6）



在“碳达峰，碳中和”的宏观战略背景下，国家大力发展以光伏为代表的新能源，在电网工作场景中光伏发电也凸显其作用，但是通过这次较为详细的数据分析，可以深刻感受到光伏发电具有“看天吃饭”的不可控性和波动性。而电网调度部门往往就是需要维持“发电”与“用电”之间的平衡，因此光伏发电在助力双碳目标的同时，也给电网调度规划发电量时带来了巨大的压力。



由实验数据可知，运用的不同模型（如随机森林模型，LSTM模型，线性回归）和预测的不同天气场景（如晴天和阴天）的预测误差均存在一定明显的误差，这些误差运用到实际发电工作中会带来许多不便：例如若误差过大，导致相应的光伏发电过少时，为应对突发情况还得使用传统的发电方式，这不仅增加了发电的成本，还意味着一定程度上会给实现双碳目标制造阻碍；若因误差过大，导致相应的光伏发电过多时，也会造成能源浪费；对于电网自身来说若因误差较大，为了应对光伏发电的波动性，往往需要备足够的储能工具，误差越大，储能成本也越大。



个人收获与感悟



此次研究是从0到1的进步，遇到了不符合预期的结果，也遇到了思想上的困境，但当我完成到这里也只是感觉到了无穷的收获。从前我在计科专业，了解了各种深度学习模型的发展与优劣势，但并未将其应用在处理具体的实际问题之中。而此次学习过后，我初次了解到了科研的大概流程，也让我体验到了科研过程中面对困难，寻求方法，解决问题，对比分析，总结改进这一系列流程后的自我成就感。



同时，我也对深度学习也有了新的认识，曾经在原专业时，我知道深度学习的好处，对比传统模型时，其展现的强大能力，而此次学习让我明白了，不是所有情况下深度学习模型就一定更好，本次小样本数据集下就可看出，LSTM模型就不如传统树模型，在实际工程中没有“最好”的算法，只有“最适合”的算法。



起初在我眼里那些数据集只是一串数字而已，但一旦我们有了想解决的问题，有了大致想研究的方向，那些不起眼的数据集就能成为我们社会不断发展中的一个不可或缺的“螺丝钉”，能为双碳目标实现助力。所以更多时候缺乏的是一个想法和一个开始。人类社会从原始社会到封建社会再到第一二次工业革命的开始都需要有人有“我有一个新想法”的提议，有创新的勇气，为我们社会发展提笔开始的序章。

最后，我也相信多积累多经历多挑战，可以让我从“不知道我知道什么”蜕变到“知道我不知道什么”。





Thank you!
谢谢大家!

汇报人:刘诗妍
日期: 10. 14

